



TEC.AZUAY
INSTITUTO UNIVERSITARIO

**TECNOLOGÍA SUPERIOR
UNIVERSITARIA EN DESARROLLO
DE SOFTWARE**

ASIGNATURA:

POO 2

TEMA:

PROYECTO FINAL

ESTUDIANTE:

FRANKLIN ANDRES ORELLANA ESPINOZA

DOCENTE:

ING. DANIEL ORTIZ

CURSO:

N6A

INFORME TÉCNICO — PIPELINE DE DATOS COVID-19 (DAGSTER)


Objetivo: Automatizar con Dagster un pipeline sobre el dataset canónico de OWID COVID-19 para Ecuador y un país comparativo, calculando métricas, validando calidad de datos y exportando resultados reproducibles.

Fuente canónica: <https://catalog.ourworldindata.org/garden/covid/latest/compact/compact.csv>

Artefactos finales: data/reporte_covid.xlsx (hojas: datos_procesados, incidencia_7d, factor_crec_7d) y data/tabla_perfilado.csv.

Evidencia en UI: Asset Checks de entrada y salida visibles en Dagster.

Estructura del repo.




ARQUITECTURA DEL PIPELINE

Assets (flujo end-to-end)

- **leer_datos**
Descarga el CSV canónico (con fallback local). Normaliza nombres a minúsculas y, si aparece country, lo renombra a location. Registra metadatos.
Resultado de tu corrida: fuente = remoto, filas = 523,599 (ver captura).
- **chequeos_entrada** (Asset Check no bloqueante sobre leer_datos)
Registra una tabla resumen de reglas (markdown). Si falla algo estricto, se detiene; los “warnings” no bloquean.
- **datos_procesados** (eager)
Convierte date a fecha, elimina nulos en new_cases y people_vaccinated, deduplica por (location,date), filtra Ecuador y el país comparativo y conserva: location, date, new_cases, people_vaccinated, population.
- **metrica_incidencia_7d** (eager)
 - $\text{incidencia_diaria} = (\text{new_cases} / \text{population}) * 100000 \rightarrow \text{promedio móvil 7d por país} \rightarrow$

columnas: fecha, pais, incidencia_7d.

- **metrica_factor_crec_7d** (eager)
 - $\text{semana_actual} = \text{sum}(\text{new_cases últimos 7 días})$; $\text{semana_prev} = \text{sum}(\text{new_cases 7 días previos})$; $\text{factor_crec_7d} = \text{semana_actual} / \text{semana_prev} \rightarrow$ columnas: semana_fin, pais, casos_semana, factor_crec_7d.
- **chequeos_salida_incidencia** (Asset Check bloqueante sobre metrica_incidencia_7d)
Valida $0 \leq \text{incidencia_7d} \leq 2000$. Si hay filas fuera de rango, falla.
- **reporte_excel_covid** (eager)
Exporta sólo resultados finales al Excel con 3 hojas.
- **eda_perfilado** (eager)
Genera data/tabla_perfilado.csv con el perfilado mínimo para Ecuador vs país comparativo.



Justificación de diseño

- Assets encadenados $\rightarrow$ separa ingesta, validación, procesamiento, métricas y exportación; facilita trazabilidad y re-materializaciones selectivas.
- Automatización: `leer_datos` corre por cron y el resto se dispara por dependencias (eager).
- Configurabilidad: país comparativo y tolerancias vía variables de entorno.
- Artefactos livianos: al repo solo va el Excel final y la tabla de perfilado (no snapshots completos).

Key	Timestamp	Value
fuelle	30 ago, 10:21 p.m.	remoto
filas	30 ago, 10:21 p.m.	523599
columnas	30 ago, 10:21 p.m.	[<pre> "location", "date", "total_cases", "new_cases", "new_cases_smoothed", "total_cases_per_million", "new_cases_per_million", "new_cases_smoothed_per_million", "total_deaths", "new_deaths", "new_deaths_smoothed", "total_deaths_per_million", "new_deaths_per_million", "new_deaths_smoothed_per_million", "excess_mortality", "excess_mortality_cumulative", "excess_mortality_cumulative_absolute", "excess_mortality_cumulative_per_million", "hosp_patients", "hosp_patients_per_million" </pre>]
path	30 ago, 10:21 p.m.	/workspaces/repositorio_clase/covid_pipeline/.tmp_dagster_home_w3420bcs/storage/leer_datos

DECISIONES DE VALIDACIÓN

Entrada (chequeos_entrada) y motivación

Reglas estrictas

- location y date no nulos → claves mínimas país-día.
- Unicidad de (location,date) → evita doble conteo.
- population > 0 y % nulos permitido ≤ 5% (configurable) → necesario para métricas per cápita.

Warnings (no bloquean)

- new_cases ≥ 0 (OWID puede tener negativos por revisiones).
- max(date) ≤ hoy (fechas futuras sugieren error de fuente).

Estado en tu corrida: el check de entrada aparece “Failed (no bloqueante)”. La causa esperable con tus datos es max(date) > hoy (en tu perfilado, fecha_max = 2025-12-28), que lo tratamos como warning documentado. El resto de reglas estrictas se cumplen.

Salida: reglas aplicadas en chequeos_salida_incidencia y motivación

- Regla: $0 \leq \text{incidencia_7d} \leq 2000$ (bloqueante) para capturar outliers/errores de escala.
Tu corrida: Passed, con filas_fuera_rango = 0.

Descubrimientos en los datos (según tu tabla_perfilado.csv)

- Rango temporal: 2020-01-01 → 2025-12-28.
- new_cases: mín = 0.0, máx = 59 470.0.
- Calidad: % nulos en new_cases ≈ 1.21%; % nulos en people_vaccinated ≈ 60.95%.
 - Implicación: para métricas y comparaciones robustas, se filtran nulos en new_cases y people_vaccinated; las brechas de vacunación (sobre todo en fases iniciales/países) deben documentarse.
- Comparación estandarizada: incidencia_7d por 100k permite comparar perfiles de contagio entre Ecuador y el país comparativo pese a diferencias de población.
- Dinámica: factor_crec_7d > 1 indica expansión semanal; < 1, contracción.

metrica,valor		
columnas,location	date	total_cases
tipos,location:object	date:datetime64[ns]	total_cases:fl
min_new_cases,0.0		
max_new_cases,59470.0		
pct_null_new_cases,1.21%		
pct_null_people_vaccinated,60.95%		
fecha_min,2020-01-01 00:00:00		
fecha_max,2025-12-28 00:00:00		

CONSIDERACIONES DE ARQUITECTURA

- pandas elegido: volumen actual (~523k filas) cabe en memoria y expone groupby/rolling simples.
- DuckDB (opción futura): si el volumen crece (multi-archivos, >10M filas) o se requieren joins/SQL ad-hoc; escribir a Parquet mejoraría I/O.
- Soda (opción de gobierno DQ): si hiciera falta monitoreo y alertas fuera de Dagster; en este proyecto bastan Asset Checks nativos.
- Operación & reproducibilidad: entorno aislado (venv/Codespaces), pip install -e ., dg dev; cron a las 06:00; sólo artefactos finales en data/.

location	date	new_cases	people_vaccin	population
Ecuador	20/1/2021	924	17	17823857
Ecuador	21/1/2021	1747	3008	17823857
Ecuador	22/1/2021	1874	3811	17823857
Ecuador	23/1/2021	969	3848	17823857
Ecuador	25/1/2021	3060	5116	17823857
Ecuador	26/1/2021	275	5876	17823857
Ecuador	27/1/2021	579	6580	17823857
Ecuador	28/1/2021	1389	6802	17823857

RESULTADOS

Métricas implementadas e interpretación

- incidencia_7d (por 100k hab.)
 - Suaviza ruido diario y permite comparar países con distinta población.

Hoja incidencia_7d

fecha	país	incidencia_7d
2021-07-01	Ecuador	10.6
2021-07-01	Perú	15.7

- factor_crec_7d
 - 1: crecimiento semanal; <1: descenso; ≈1: meseta.

Hoja factor_crec_7d

semana_fin	país	casos_semana	factor_crec_7d
2021-07-07	Ecuador	12 500	1.15
2021-07-07	Perú	35 000	0.92

Resumen de calidad

- Entrada — chequeos_entrada: Failed (no bloqueante).
 - Motivo principal observado: $\max(\text{date}) > \text{hoy}$ (warning documentado por OWID).
 - Reglas estrictas (OK): location/date no nulos, unicidad (location,date), population > 0 y % nulos de population bajo el umbral.
- Salida — chequeos_salida_incidencia: Passed, filas_fuera_rango = 0.